COMPETICIÓN DE REGRESIÓN EN KAGGLE.

Bruno Otero Galadí

CORREO: bruogal@gmail.com

CAPTURA DE LA TABLA *LEADERBOARD* DE KAGGLE.

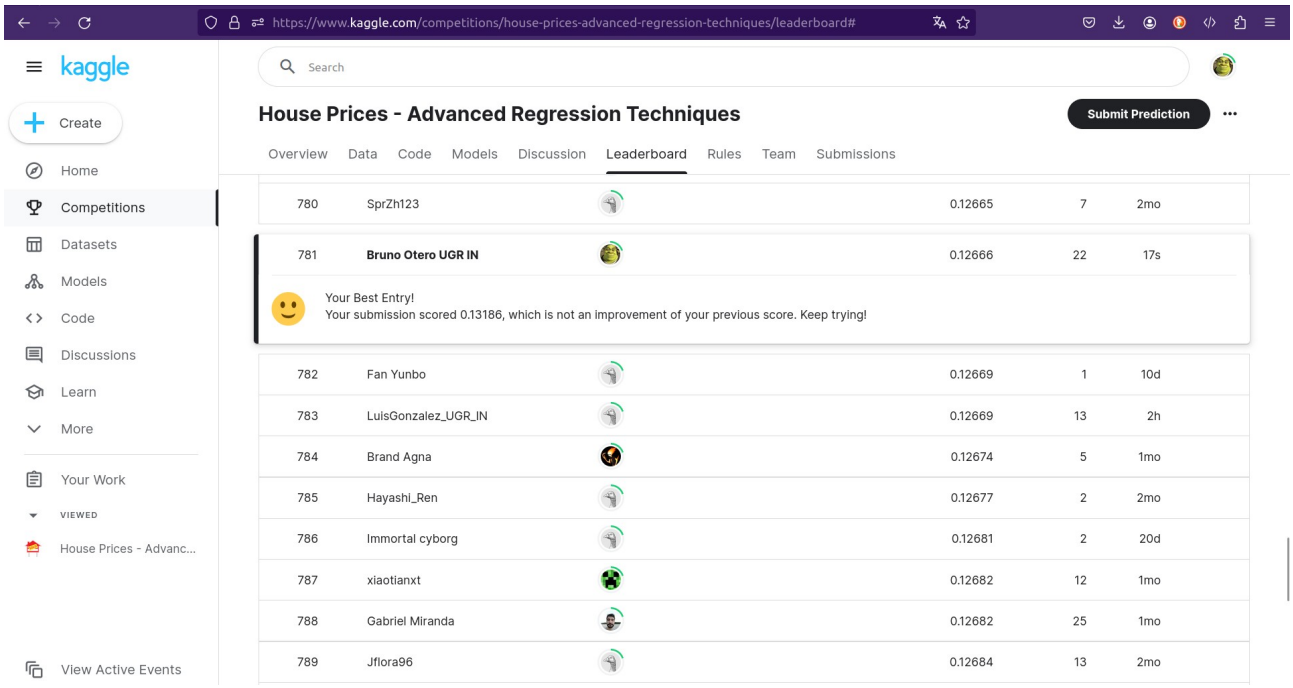

TABLA DE RESULTADOS DE TODAS LAS SUBIDAS A KAGGLE.

HORA DE SUBIDA	RÁNKING EN EL MOMENTO DE LA SUBIDA	FECHA DE SUBIDA	SCORE SOBRE EL CONJUNTO DE DATOS DE ENTRENAMIENTO	SCORE OBTENIDO EN KAGGLE	PREPROCESAMIENTO	ALGORITMOS EMPLEADOS Y PARÁMETROS DE CONFIGURACIÓN
14:04	4656	21 diciembre de 2023	Ninguno. No hay script de Python asociado a esta primera subida.	0.40613	Ninguno.	Ninguno. Se han usado los datos de prueba. No hay script de Python asociado a esta primera subida.
21:22	3943	28 diciembre de 2023	No se ha calculado el score sobre los datos de entrenamiento.	0.28444	Codificación de variabes categóricas con preprocessing.LabelEncoder. Se intentaron limpiar los valores NaN pero no se consiguió.	Árbol de regresión (porque acepta valores NaN) con random_state = 0.
10:12	3715	30 diciembre de 2023	-0.04700413859978	0.20104	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana.	Árbol de regresión con valores por defecto.
10:44	3715	30 diciembre de 2023	-0.05227070192202	0.24011	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana.	Modelo de regresión KNN con K=3.
10:59	3716	30 diciembre de 2023	-0.05078207118632	0.24006	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana.	Modelo de regresión KNN con K=8 optimizado con GridSearch.
12:22	3719	30 diciembre de 2023	-0.04884603380260	0.23501	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con	Modelo de bagging con 100 instancias a partir de un modelo KNN cuyos mejores parámetros “n_neighbors”, “weights”,

					la función mediana.	“algorithm” y “leaf_size” se han hallado usando GridSearch.
23:32	3677	1 enero 2024	-0.04894968628732	0.23485	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos y numéricos usando objetos IterativeImputer con parámetro estimator definido como un modelo RandomForest.	Modelo de bagging con 100 instancias a partir de un modelo KNN cuyos mejores parámetros “n_neighbors”, “weights”, “algorithm” y “leaf_size” se han hallado usando GridSearch.
00:09	3487	3 enero 2024	-0.03196773796941	0.17786	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de bagging con 100 instancias a partir de un modelo KNN cuyos mejores parámetros “n_neighbors”, “weights”, “algorithm” y “leaf_size” se han hallado usando GridSearch.
00:25	3487	3 enero 2024	No se ha podido calcular por no haber podido calcular una de las medidas de las que se realiza la estimación final. Según el mensaje de error, se debe a operaciones indebidas con valores negativos.	0.4562	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de bagging con 100 instancias a partir de un modelo de red neuronal MLPRegressor cuyos mejores parámetros se han hallado usando GridSearch.
00:36	2699	3 enero 2024	-0.02158162119215	0.14975	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con	Modelo de bagging con 100 instancias a partir de un modelo de árbol de regresión cuyos mejores parámetros se han hallado usando GridSearch.

					un objeto StandarScaler.	
20:48	935	4 enero 2024	-0.01603558092819	0.12833	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de bagging con 100 instancias a partir de un modelo XGBoost cuyos mejores parámetros se han hallado usando GridSearch.
20:49	876	4 enero 2024	-0.01597873009799	0.1277	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de bagging con 200 instancias a partir de un modelo XGBoost cuyos mejores parámetros se han hallado usando GridSearch tomando como referencia los de la subida anterior.
20:59	882	5 enero 2024	-0.01747786858686	0.13686	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de stacking construido con un modelo KNN, un árbol de regresión y un XGBoost, los tres configurados con los mejores parámetros psoibles con GridSearch.
21:01	844	5 enero 2024	-0.01510576490673	0.12731	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de stacking construido con tres modelos bagging de 100 instancias cada uno: un modelo KNN, un árbol de regresión y un XGBoost, los tres configurados con los mejores parámetros posibles con GridSearch.
22:50	827	7 enero	No se ha podido	0.14421	Aprendizaje con datos	Modelo de stacking

		2024	calcular por no haber podido calcular una de las medidas de las que se realiza la estimación final. Según el mensaje de error, se debe a operaciones indebidas con valores negativos en el modelo de regresión lineal.		de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	construido con cinco modelos bagging de 100 instancias cada uno: un modelo KNN, un árbol de regresión, un XGBoost, un modelo de regresión lineal y un modelo de espacio vectorial de regresión, los cinco configurados con los mejores parámetros posibles con GridSearch.
22:51	781	7 enero 2024	-0.01555277810926	0.12666	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de stacking construido con cuatro modelos bagging de 100 instancias cada uno: un modelo KNN, un árbol de regresión, un XGBoost y un modelo de espacio vectorial de regresión, los cuatro configurados con los mejores parámetros posibles con GridSearch.
22:54	781	7 enero 2024	-0.01604727328635	0.12791	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de stacking construido con tres modelos bagging de 100 instancias cada uno: un modelo KNN, un XGBoost y un modelo de espacio vectorial de regresión, los tres configurados con los mejores parámetros posibles con GridSearch.
22:59	781	7 enero 2024	-0.01621481554918	0.12807	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con	Modelo de stacking construido con seis modelos bagging de 100 instancias cada uno: un modelo KNN, un XGBoost, un árbol de

					la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	regresión, un modelo de espacio vectorial de regresión, un hist gradient boosting y un gradient boosting, los seis configurados con los mejores parámetros posibles con GridSearch.
23:14	781	7 enero 2024	-0.01568297113424	0.1273	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de stacking construido con tres modelos bagging de 100 instancias cada uno: un XGBoost, un hist gradient boosting y un gradient boosting, los tres configurados con los mejores parámetros posibles con GridSearch.
23:34	781	7 enero 2024	-0.01791220886694	0.13485	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de voting construido con cuatro modelos bagging de 100 instancias cada uno: un modelo KNN, un árbol de regresión, un XGBoost y un modelo de espacio vectorial de regresión, los cuatro configurados con los mejores parámetros posibles con GridSearch.
23:35	781	7 enero 2024	-0.01596511696253	0.12796	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo de voting construido con tres modelos bagging de 100 instancias cada uno: un XGBoost, un hist gradient boosting y un gradient boosting, los tres configurados con los mejores parámetros posibles con GridSearch.

23:35	781	7 enero 2024	-0.01702411449325	0.13186	Aprendizaje con datos de test+entrenamiento, reemplazo de valores categóricos perdidos con el más frecuente, reemplazo de valores numéricos perdidos con la función mediana. Escalado final de valores de entrenamiento y test con un objeto StandarScaler.	Modelo voting con seis modelos bagging de 100 instancias: un KNN, un XGBoost, un árbol de regresión, un modelo de espacio vectorial, un hist gradient boosting y un gradient boosting, los seis con los mejores parámetros posibles con GridSearch.

BIBLIOGRAFÍA.

1.https://realpython.com/knn-python/#knn-is-a-supervised-machine-learning-algorithm

2.https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html

3.https://stackoverflow.com/questions/64900801/implementing-knn-imputation-on-categorical-variables-in-an-sklearn-pipeline

4.https://scikit-learn.org/stable/modules/neural_networks_supervised.html#regression

5.https://xgboost.readthedocs.io/en/stable/parameter.html

6.https://machinelearningmastery.com/stacking-ensemble-machine-learning-with-python/

7.https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.VotingRegressor.html